

Regressionsmodell, försäljningspris bilar:

Prediktion och statistik analys

Data-set Blocket bilannonser



ECUTBILDNING



Katarina Persson
EC Utbildning
Kunskapskontroll R
2025-04

Abstract

Since industrialization, car ownership has increased steadily, and in Västra Götaland County, data shows a clear growth between 2010 and 2025, which underlines a strong market with high demand. Against this background, a need is identified for a statistical model to predict sales prices based on central factors. The Blocket Volvo dataset was collected manually from Blocket's website and consists of 900 data points from car advertisements, with variables such as mileage, fuel type and model year. Basic data management was carried out with Excel, and the model was developed in R with a focus on machine learning processes such as training, validation and testing. The regression analysis evaluated theoretical assumptions, the significance of the variables, the strength of the effects and confidence intervals to ensure the validity and reliability of the model.


Skapas automatiskt i Word genom att gå till Referenser > Innehållsförteckning.

Innehållsförteckning

Abstract	2
1 Inledning.....	1
2 Teori.....	3
2.1 Prediktion.....	3
2.1.1 Linjär Regressionsmodell	3
2.1.2 EDA och databehandling	3
2.1.3 Modellval	3
2.1.4 Träning, validering och test.....	3
2.1.5 Utvärderingsmetoder	3
2.2 Statistik slutledning.....	3
2.2.1 Teoretiska antagande för statistisk analys	3
2.2.2 Antagandet om normalfördelning och linjäritet i datamaterial.....	3
2.2.3 Korellerade residulaler	3
2.2.4 Heteroskedasticitet	3
2.2.5 Normalfördelning av residualer	3
2.2.6 Outliers	3
2.2.7 High leverage-punkter	4
2.2.8 Kollinariet och Multikollinearitet	4
2.3 Intervallskattning	4
2.4 Konfidensintervall.....	4
2.5 Prediktionsintervall.....	4
2.6 Hypotesprövning.....	4
2.7 Residualanalys	4
2.8 Signifikanta variabler och utvärdering av deras effekter	4
3 Metod.....	6
3.1 Datainsamling	6
3.1.1 Externa data	6
3.1.2 Blocket Data	6
PX-WEB API Interface for R.....	Fel! Bokmärket är inte definierat.
4 Resultat och Diskussion	10
4.1 Normalitet och linjäritet.....	10
5 Slutsatser	15
6 Teoretiska frågor.....	16

6.1	Beskriv kortfattat vad en Quantile-Quantile (QQ) plot.....	16
6.2	Din kollega Karin frågar dig följande: ”Jag har hört att i maskininlärning så är fokus på prediktioner medan man i statistisk regressionsanalys kan göra såväl prediktioner som statistisk inferens. Vad menas med det, kan du ge några exempel?.....	16
6.3	Vad är skillnaden på ”konfidensintervall” och ”prediktionsintervall” för predikterade värden? 17	
6.4	Den multipla linjära regressionsmodellen kan skrivas som: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$. Hur tolkas beta parametrarna?.....	17
6.5	Din kollega Nils frågar dig följande: ”Stämmer det att man i statistisk regressionsmodellering inte behöver använda träning, validering och test set om man nyttjar mått såsom BIC? Vad är logiken bakom detta?” Vad svarar du Nils?.....	17
6.6	Förklara algoritmen nedan för Best subset selection	18
6.7	Ett citat från statistikern George Box är: “All models are wrong, some are useful. Förklara vad som menas med det citatet.	18
7	Självutvärdering	20
	Appendix A	22
	Källförteckning.....	23

1 Inledning



Sedan industrialiseringens början på 1900-talet, då bilen introducerades på marknaden, har antalet ägda bilar stadigt ökat globalt. Diagrammet visar en tydlig trend av ökat ägande av personbilar i Västra Götalands län mellan 2010 och 2025, vilket speglar en stark marknad med hög efterfrågan på bilar.

Eftersom bilförsäljning utgör en stor och växande marknad, finns ett tydligt behov av att utveckla en statistisk modell som möjliggör prediktion av försäljningspriser, och mot bakgrund av det, har en sådan modell byggts baserat på ett antal identifierade faktorer.

Förarbetet med datasetet Blocket Volvo inkluderade grundläggande datahantering i Excel, med fokus på att säkerställa noggrannhet och effektivitet. Teoretiska frågor inom statistik, såsom mått-utvärdering och algoritmbeskrivning, behandlades också.

Datasetet samlades in manuellt från Blockets hemsida genom ett samarbete inom klassen, där totalt 900 datapunkter från annonser samlades in. Variabler som miltal, bränsletyp och årsmodell låg till grund för modelleringen. Modellen implementerades i R och utvärderades med hjälp av adjusted R^2 och RMSE för att kvantifiera prediktionsfel och bedöma modellens robusthet och tillförlitlighet.

Slutligen analyserades modellen för att utvärdera teoretiska antaganden och deras påverkan på resultaten. Analysen identifierade signifikanta variabler, deras effektstyrka och konfidensintervall, samtidigt som hypotesprövningar säkerställde modellens validitet och tillförlitlighet.

Syftet med arbetet är undersöka och besvara centrala frågeställningar kopplade till teoretiska antaganden och praktiska statistiska processer. Fokus ligger på att utvärdera följande:

Undersökning av nedanstående teoretiska antaganden

Normalitet, och icke linjära samband	Korrelerade residualer
Heteroskedasticitet	Normalfördelning av residualer
Outliers	High leverage-punkter
Multikollinearitet	

Teorifrågor med inriktning praktiska statistik processer

2 Teori

2.1 Prediktion

2.1.1 Linjär Regressionsmodell

2.1.2 EDA och databehandling

2.1.3 Modellval

2.1.4 Träning, validering och test

2.1.5 Utvärderingsmetoder

2.2 Statistik slutledning

2.2.1 Teoretiska antagande för statistisk analys

2.2.2 Antagandet om normalfördelning och linjäritet i datamaterial

Normalfördelningen och linjäritet är två centrala antaganden inom statistisk analys och modellering. Normalfördelningen är en klockformad fördelning där en majoritet av observationerna ligger nära medelvärdet, medan avvikelser gradvis blir mindre vanliga. Detta är grundläggande för att tolka data och dra statistiska slutsatser. En nyckelprincip är att cirka 95 % av observationerna faller inom ± 1.96 standardavvikelser från medelvärdet, vilket ger en signifikansnivå på 0.05.

Linjäritet avser det antagande att sambandet mellan oberoende och beroende variabler är linjärt. Residualerna används för att bedöma detta antagande. Ett linjärt mönster med normalfördelade residualer indikerar att modellen korrekt fångar sambandet mellan variablerna. Avvikelser från linjäritet kan signalera behovet av att använda andra modeller eller transformera data.

Den centrala gränsvärdessatsen spelar en avgörande roll i båda dessa sammanhang. Den säger att medelvärdet av stora stickprov tenderar att följa en normalfördelning, oavsett ursprungsfördelningen. Detta möjliggör analys även när datan inte är perfekt normalfördelad, förutsatt att stickprovsstorleken är tillräcklig ($30 < n < 50$). Genom att koppla denna princip till både normalfördelning och linjäritet kan analysen säkerställa robusthet och tillförlitliga resultat.

2.2.3 Korellerade residualer

2.2.4 Heteroskedasticitet

2.2.5 Normalfördelning av residualer

2.2.6 Outliers

2.2.7 High leverage-punkter

High Leverage Points och Modellpåverkan High leverage points är observationer som har extrema värden i de oberoende variablerna och kan därmed ha en betydande inverkan på regressionens resultat. Genom att påverka modellens anpassning kan dessa punkter dra regressionslinjen närmare sig, vilket potentiellt leder till snedvridna estimat och minskad tillförlitlighet i modellen.

För att bedöma effekten av high leverage points kan regressionen genomföras både med och utan dessa punkter för att identifiera deras påverkan på modellens prestanda. En grundlig analys av resultaten möjliggör en mer informerad bedömning av huruvida punkterna med rimlig säkerhet bör plockas bort eller eventuellt ersättas med nytt datamaterial.

Hatvärden används för att kvantifiera påverkan från enskilda observationer, där höga värden indikerar att en observation har stort inflytande på modellens prediktioner. Ett ytterligare mått är Cook's Distance, som identifierar observationer med betydande effekt på regressionens koefficienter. Dessa verktyg ger värdefulla insikter i modellens robusthet och stödjer beslutsfattandet kring hantering av high leverage punkter, behandla, ta bort eller låta vara då de inte har någon nämnvärd påverkan.

2.2.8 Kollinariet och Multikollinearitet

2.3 Intervallskattning

2.4 Konfidensintervall

2.5 Prediktionsintervall

2.6 Hypotesprövning

2.7 Residualanalys

2.8 Signifikanta variabler och utvärdering av deras effekter

3 Metod

3.1 Datainsamling

I kunskapskontrollen, till skillnad från de tidigare, har studenterna, individuellt eller i grupp, ansvarat för datainsamlingen – en avgörande del av arbetet med regressionsmodellen. Arbetet har genomförts med en kombination av manuella metoder och API-anrop, där de manuella metoderna innefattade direkt insamling av specifika data från primärkällor och registrering av relevanta variabler.

Det nya angreppssatsen, och olika datainsamlingsmetoder, rensade och sammanställda med Excel, har inneburit att praktiskt utforska tekniska lösningar och utveckla en ny förståelse för datainsamlingens roll.

3.1.1 Externa data

För att skapa kontext till behovet av att prediktera försäljningspriset på personbilar, har extern data hämtats via SCB:s API, pxweb. Instruktioner och manual för arbetet återfinns på SCB:s webbplats. Datainsamlingen har utförts med hjälp av R och resultaten presenteras i en graf i uppsatsens inledning.

3.1.2 Blocket Data

Syftet med multipel regressionsmodellen är att förutsäga försäljningspriset på Volvo-personbilar genom statistisk analys. Modellen bygger på 13 oberoende variabler, X_0 till X_{12} , som påverkar den beroende variabeln Y , försäljningspriset. De oberoende variablerna inkluderar faktorer som miltal, modellår, säljare, bilmodell, växellåda, hästkrafter, bränsletyp och drivning—alla variabler som potentiellt påverkar bilens värde. Blocket-annonser innehåller på grundnivå 12 oberoende variabler, och utöver dessa har vi lagt till säljartyp och region för att skapa en heltäckande analys, insamling av numeriska och kategoriska värden enligt nedanstående tabell.

Försäljningspris	Säljare	Bränsle	Växellåda	Drivning	Hästkrafter	Miltal
numeriskt	binär, nominal	nominal	binär nominal	binär nominal	numerisk	numerisk
Modellår	Biltyp	Färg	Motorstorlek	Modell	Region	
numerisk	multi, nominal	multi, nominal	numerisk	multi nominal	multi, nominal	

I diskussionerna i klass D24, kring datainsamling, valdes ett antal Volvo personbilar ut från Blocket Bil, och deras prisdynamik på marknaden, ett prisspann från 5 000 kr till 890 000 kr ett väldigt brett dataset allt från äldre, budgetvänliga modeller till topptrustade lyxbilar.

Målet med modell, är i huvudsak att utforska vilka faktorer som har störst inverkan på priset—är det miltalet, årsmodellen, motorstyrkan eller kanske säljartypen som spelar den avgörande rollen?

Datainsamlingen i arbetet har påverkats av Blockets användarregler, vilka förbjuder automatiserad insamling av data, såsom web scraping. För att säkerställa att studien följde dessa riktlinjer kontaktades Blocket med en förfrågan om tillstånd att samla in data i studiesyfte. Svaret vi mottog resulterade i en moment 22-situation, där Blocket hänvisade till att insamling endast får ske med tillstånd—vilket var just det som arbetsgruppen hade ansökt om. Då frågan aldrig adresserades konkret och arbetsgruppen inte såg anledning att driva ärendet vidare till bolagets juristavdelning, valdes istället en alternativ metod.

För att säkerställa en reglerad och systematisk insamling av relevant data genomfördes insamlingen manuellt. Varje student registrerade 50 bilannonser från Blocket i olika regioner i Sverige, vilket möjliggjorde en kontrollerad kartläggning av marknadstrender.

Vidare har vi diskuterat juridiska aspekter kring datainsamling och frågan om huruvida automatiserad insamling utgör ett lagbrott. Även om det inte nödvändigtvis klassas som ett brott, kan det innebära en immaterialrättslig överträdelse då företags material används utan tillstånd.

Grupp för datainsamlingen, upprättad ett Excel-blad där varje student fick en egen flik., upplagt på Teams, därefter registrerade vi 50 Blocket-annonser var, enligt de direktiv som fastställts i en mall i filen. Totalt insamlades cirka 900 datapunkter för vidare bearbetning och analys.

För att uppfylla minimikravet på drygt 10 observationer per variabel och säkerställa att den statistiska analysen håller god kvalitet, valdes att samla in data baserat på en fördelning där varje student bidrar med 50 datapunkter. Med totalt 13 variabler i modellen innebär detta att vi uppfyller kravet på minst 130 observationer ($13 * 10$). Denna strategi ger ett dataset som både möter de metodologiska kraven och är hanterbart för varje deltagare.

Insamlingsstrategin skapar också möjlighet till variation i datasetet, då data från olika regioner och olika typer av fordon inkluderas. Detta stärker modellens generaliserbarhet och bidrar till en mer robust analys.

Under arbetet har betydelsen av att hantera missing values (NA), specialtecken, dolda mellanrum och stavfel blivit tydlig. Dessa faktorer påverkar datakvaliteten, vilket gör förarbetet i Excel avgörande för att säkerställa ett väl strukturerat och rent dataset inför analys i R.

Avslutningsvis är det viktigt att ha en tydlig strategi för modellens uppbyggnad och vilka data som behövs. En genomtänkt metodik sparar tid och förbättrar analysens kvalitet.

Momentet att läsa in och skapa en dataframe i R, på datasetet som insamlats, genomfördes utan anmärkningar, och den insamlade datan visade sig möjliga för vidare analys och modellering.

I arbetet med kunskapskontroll R Programmering med Statistik ingick jag i en grupp med följande personer från klass D24: Alvin, Arash, Ana, Emad, Gayathree, Hani,Joakim, Mikael, My, Peter, Per, Sharmin, Rana, Tahira, Tural, Zakariyae.

Lärdomar från processen med manuell datainsamling Att samla in data manuellt tar betydligt längre tid än uppskattat och kan vara en monoton process. Samtidigt är det viktigt att säkerställa god datakvalitet – om en bilannons saknar viktiga parametrar, bör den uteslutas, och endast fullständiga dataset inkluderas.

3.2 Regressionmodulering

Det manuellt skapade datasetet lästes in till R. Blocket-data för bilar omfattar 899 observationer och innehåller ursprungligen 13 variabler, varav ungefär hälften är kategoriska.

Inledningsvis genomfördes en explorativ dataanalys (EDA) för att erhålla en övergripande förståelse av datamaterialet. Detta innefattade inspektion av datasetets struktur med hjälp av funktionerna `head()`, `summary()` och `dim()`, samt kontroll av potentiella tomma kolumner och rader. Vid denna process identifierades och eliminerades samtliga kvarvarande NA-värden för att säkerställa datakvalitet och undvika störningar i den vidare analysen.

För att bedöma datamaterialet utifrån teoretiska statistiska förutsättningar har försäljningspriset visualiserats med en QQ-plot. En fördjupad diskussion kring detta presenteras i kapitel 4, där resultaten analyseras samt de statistiska förutsättningarna för vidare analys diskuteras.

Vidare har de numeriska variablerna, inklusive försäljningspriset, visualiserats med `ggplot`. En densitetsplott har genererats för att bedöma hur väl materialet följer en normalfördelning. För ytterligare jämförelse har en Gauss-kurva inkluderats, vilket möjliggör en direkt jämförelse mellan de observerade värdena och det teoretiska idealvärdet. Frågan om normalfördelning kommer att behandlas senare i rapporten.

Kategoriska variabler



Datasetet innehåller tre kategoriska variabler: säljare (privat eller företag), växellåda (manuell eller automat) samt drivning (fyr- eller tvåhjulsdreven), som kodades direkt binärt, och ursprungsvariablerna plockades bort.



Det fanns fem ytterligare bilrelaterade variabler med flera kategoriska nivåer, vilka kodades med one-hot encoding med hjälp av `dplyr` och `caret` från `tidyverse`. De nya variablerna integrerades sedan i datasetet genom `bind`, vilket expanderade datasetets dimensioner till 899×79 .


I R valdes 4 modeller ut för multirregression

4 Resultat och Diskussion

4.1 Normalitet och linjäritet







Normalfördelningen och linjäritet är två centrala teoretiska antaganden inom statistisk analys som påverkar modellens prestanda och robusthet. För att säkerställa att resultaten från statistiska tester och regressionsanalyser är tillförlitliga, undersöks dessa aspekter särskilt

Normalitet

Test av normalitet gav blandade resultat:

- **Shapiro-Wilk-testet** förkastade normalitet ($p = 2.477e-08$), vilket kan bero på testets känslighet för små avvikelser i stora dataset.
- **Kolmogorov-Smirnov-testet** godkände normalitet ($p = 0.2346$) och indikerade att data är nära normalfördelade.
- **Anderson-Darling-testet** förkastade normalitet ($p = 0.001787$), med avvikelser huvudsakligen i svansarna.

En QQ-plot visualiserade dessa avvikelser med en S-form, vilket tydde på att svansarna inte är helt perfekta. Trots dessa avvikelser är datasetets storlek (~900 observationer) tillräckligt stort för att centrala gränsvärdessatsen ska säkerställa att analysen kan genomföras med parametriska metoder, eftersom stickprovsmedelvärden tenderar att följa en normalfördelning.

Sammanfattning: Ibland blir det skeva toppar, konstiga svansar eller helt oväntade mönster som gör att man undrar om datan ens förstår att den ska bete sig normalt.

Linjäritet

Modellens linjäritet bedömdes genom residualanalys och scatterplots. Residualerna uppvisade vissa avvikelser från perfekta linjära samband, men de följer ändå huvudsakligen ett linjärt mönster. Den stora datamängden förstärker modellens robusthet och förmåga att ge tillförlitliga prediktioner, trots mindre avvikelser.

Trots att datasetet inte uppfyller antaganden om perfekt normalitet och linjäritet gör jag bedömningen att det, inte påverkar modellens prediktiva förmåga i nämnvärd grad. Den centrala gränsvärdessatsen och datasetets storlek gör att resultaten kan anses vara robusta och tillförlitliga, och parametriska modeller kan användas i analysstegen.

RMSE för olika modeller	
Enkel Linjär Regression	xx
Lasso	xx
Ridge	xx

Tabell 1: Root Mean Squared Error (RMSE) för de fyra valda modellerna.

Det insamlade datasetet har en betydande spridning i både försäljningspriser och bilens modellår, med priser som sträcker sig från 5000 kr till 849 000 kr och modellår från 1972 till 2025. Denna stora variation kan ge regressionsmodellen utmaningar när det gäller att identifiera tydliga mönster och göra exakta prediktioner. För framtida studier kunde en mer avgränsad datainsamling, exempelvis med fokus på specifika bilmärken eller prisintervall, bidra till att skapa en mer riktad och generaliserbar modell.

Vidare har det noterats att datasetet inte uppvisar en normalfördelning utan är istället förhållandevis skevt. Detta kan potentiellt bero på de utvalda insamlingsmetoderna samt urvalskriterierna, vilket kan ha resulterat i en över- eller underrepresentation av vissa grupper i datan. Denna skevhet kan i sin tur ha påverkat modellens prestanda och dess förmåga att generera pålitliga prediktioner. En framtida förbättring skulle kunna vara att använda mer balanserade urvalstekniker.

5 Slutsatser

Här besvarar du bl.a. frågeställningarna.

6 Teoretiska frågor

6.1 Beskriv kortfattat vad en Quantile-Quantile (QQ) plot

En **QQ-plot** (Quantile-Quantile plot) är ett grafiskt verktyg som används för att undersöka om ett dataset följer en viss teoretisk fördelning, oftast en **normalfördelning**. Den fungerar genom att jämföra de teoretiska kvartilerna från den antagna fördelningen med de observerade kvartilerna från datasetet.

På en QQ-plot plottas kvantilvärdena från data mot kvantilvärdena från en referensfördelning (t.ex. en normalfördelning). Om data följer den antagna fördelningen kommer punkterna att ligga nära en **rak linje**, vilket tyder på att antagandet om fördelning är korrekt.

En vanlig användning av QQ-plots är i samband med **linjär regression**, där man kan kontrollera om residualerna (feltermerna) är normalfördelade. Detta är en viktig förutsättning för att kunna göra korrekta statistiska inferenser från modellen.

När punkterna på QQ-plottet ligger nära en rak linje, är det ett tecken på att data kan antas vara **normal fördelat**. Om punkterna avviker från linjen, särskilt vid de yttersta kvartilerna, kan det indikera att data inte följer den förväntade fördelningen.

6.2 Din kollega Karin frågar dig följande: ”Jag har hört att i maskininlärning så är fokus på prediktioner medan man i statistisk regressionsanalys kan göra såväl prediktioner som statistisk inferens. Vad menas med det, kan du ge några exempel?”

En modell inom maskininlärning bygger ofta på statistiska samband, exempelvis regressionsanalys, och målet är att skapa en modell som kan förutse något baserat på tidigare data. Efter träning och testning ska modellen kunna generalisera och ge korrekta prediktioner på ny, tidigare osedd data.

Vanliga exempel inkluderar att förutsäga prisutveckling, såsom aktiekurser, eller att lösa klassificeringsproblem, till exempel churning (förutsäga om kunder lämnar eller stannar) eller att hantera spam-mail.

I maskininlärning fokuserar modellen på sina interna parametrar för att optimera prediktioner. Detta skiljer sig från statistisk inferens, där fokus ligger på att kvantifiera och tolka sambanden mellan variabler, ofta genom att fastställa konfidensintervall eller testa hypoteser för att säkerställa att resultaten är statistiskt signifikanta.

Vid utvärdering av en maskininlärningsmodell används nyckeltal som F1-score, accuracy, precision och recall, med fokus på modellens förmåga att göra prediktioner. Däremot används verktyg som SHAP (SHapley Additive exPlanations) för att tolka och förstå hur olika variabler påverkar modellens förutsägelser, vilket är viktigt inom områden som medicin, finans och juridik, där transparens och förtroende spelar en avgörande roll. Detta gör metoden mer "whitebox" och tydlig, vilket underlättar både förståelsen och kontrollen av resultaten.

6.3 Vad är skillnaden på ”konfidensintervall” och ”prediktionsintervall” för predikterade värden?

Skillnaden mellan ett konfidensintervall och ett prediktionsintervall är att konfidensintervallet talar om var väntevärdet troligen ligger, medan prediktionsintervallet talar om var en framtida observation troligen ligger, och är ett bredare intervall.

6.4 Den multipla linjära regressionsmodellen kan skrivas som: $Y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p + \varepsilon$. Hur tolkas beta parametrarna?

β_0 : interception, det förväntade värde på den beroende variabeln Y som ges när samtliga oberoende variabler $X_0 - X_p$ är 0, skärning med y-axeln, så att säga modellens startpunkt.

Betavärdet är en regressionskoefficient som anger lutningen i modellen, vilket representerar den förväntade förändringen i den beroende variabeln (Y_p) som sker när en enskild oberoende variabel (X_p) ökar med en enhet, medan alla andra variabler i modellen hålls konstant. Så beta värdena anger hur stort bidrag varje enskild variabel X ger till Y predikterat värde.

6.5 Din kollega Nils frågar dig följande: ”Stämmer det att man i statistisk regressionsmodellering inte behöver använda träning, validering och test set om man nyttjar mått såsom BIC? Vad är logiken bakom detta?” Vad svarar du Nils?

BIC (Bayesian Information Criterion), är ett mått som använd för att utvärdera modeller, genom att säkerställa en rimlig balans mellan fit och komplexitet.

Utvärderingsmättet BIC kan inte sägas ersätta träning validerings och testkörningen, eftersom modellen lär sig inte av en utvärdering, utan måste fortfarande tränas, valideras och testas för att utvecklas och bli robust.

Måttet används för att utvärdera och rangordna modeller, men det görs först efter att modellen är inkörd, tränad och körd på test set, så logiken är utvärdering hur bra modellen presterar i förhållande till dess komplexitet.

6.6 Förklara algoritmen nedan för Best subset selection

Algorithm 6.1 *Best subset selection*

1. Let $\mathcal{M}_0$ denote the *null model*, which contains no predictors. This model simply predicts the sample mean for each observation.
 2. For $k = 1, 2, \dots, p$:
 - (a) Fit all $\binom{p}{k}$ models that contain exactly k predictors.
 - (b) Pick the best among these $\binom{p}{k}$ models, and call it $\mathcal{M}_k$. Here *best* is defined as having the smallest RSS, or equivalently largest R^2 .
 3. Select a single best model from among $\mathcal{M}_0, \dots, \mathcal{M}_p$ using the prediction error on a validation set, C_p (AIC), BIC, or adjusted R^2 . Or use the cross-validation method.
-

Algoritmen utgår från M_0 , inception där Y visst värde, skärningen med Y -axeln och samtliga $X_0 - X_n$ är 0.

Därefter modellen M_k , träna alla modeller p som har k features, det finns $p! / 1 * (p-1)!$
Slutligen beräknas för varje modell ett mått antingen RSS (Residual sum) eller R^2 och välj bland dem, den som har bäst resultat.

6.7 Ett citat från statistikern George Box är: “All models are wrong, some are useful. Förklara vad som menas med det citatet.

George Box betonar att alla modeller – oavsett om det är enkla matematiska modeller, linjära regressioner eller komplexa teorier som Einsteins relativitet – är ofullständiga och imperfekta. Modeller är förenklingar av verkligheten och kan aldrig fullt ut beskriva den komplexa och mångfacetterade naturen av världen omkring oss. Modeller är därför alltid "fel" i den meningen att de inte exakt återspeglar verkligheten.

Däremot innebär det inte att modeller är värdelösa. Vissa modeller kan vara mycket nyttiga för att förklara, förutsäga eller förstå olika fenomen. Nyttigheten ligger i att modellerna gör det möjligt för oss att ta informerade beslut, lösa problem eller genomföra experiment, även om vi vet att de inte är helt perfekta.

Enkelhet och användbarhet är också viktiga principer när vi arbetar med modeller. Ofta är den enklaste modellen den mest användbara, eftersom den är lättare att förstå och implementera. Detta kan relateras till Occams rakkniv, som säger att vi bör föredra de enklaste förklaringarna som kräver färre antaganden. Trots sin enkelhet har dessa modeller praktiska tillämpningar, men vi måste vara medvetna om att de alltid innehåller någon grad av osäkerhet.

Vetenskapen och kunskapen är ständigt i utveckling, och vi strävar efter att förfinas och förbättra modeller över tid. Genom att använda modeller iterativt och testa dem mot nya data kan vi gradvis ersätta gamla modeller med mer precisa och användbara versioner.

För att sammanfatta, kan citatet från Yuval Noah Harari förtydliga tanken:

"Scientists generally agree that no theory is 100 percent correct. Thus, the real test of knowledge is not truth, but utility. Science gives us power. The more useful that power, the better the science."

Detta innebär att vetenskapens värde inte ligger i att vi hittar den "perfekta" modellen, utan att de modeller vi utvecklar är användbara och ger oss kraft att förstå och agera i världen.

7 Självutvärdering

1. Vad tycker du har varit roligast i kunskapskontrollen?

Efter nio månader av intensiv utbildning har vi fått grunderna för att kunna arbeta inom dataanalys på en grundläggande nivå, förberedelse inför kommande LIA period.

Det mest intressanta i detta projekt har varit att vi fått hantera data från start till mål – från datainsamling, rensning i Excel och att lösa de olika utmaningar som uppstod under R-körningen. Vi har jobbat självständigt med projektet, tagit reda på information, genomfört analyser och dragit egna slutsatser, samt dokumenterat och argumenterat för dem. Att dessutom testa maskininlärning i R och jämföra dess metoder med Python har varit särskilt spännande och gett en bredare förståelse för olika tekniker inom dataanalys.

2. Hur har du hanterat utmaningar? Vilka lärdomar tar du med dig till framtida kurser?

Utmaningar

Under projektets gång har flera utmaningar uppstått, vilket har lett till viktiga insikter inom datahantering, analys och metodval.

- Datainsamling: Processen har varit monoton och tidskrävande, med risk för felaktigheter. Noggrannhet har varit avgörande för att säkerställa att insamlad data är korrekt och komplett.
- Efterbearbetning i Excel: Trots noggrann rensning kvarstod dolda fel, såsom specialtecken, osynliga mellanrum och stavfel, vilket försvårade vidare analys i R.
- R-programmering: Filhantering och variabelhantering i R visade sig ha egenheter som krävde flera omstarter och återinläsningar av dataset för att kunna fortsätta analysen.
- Datasetets struktur: Datasetet var skevt och icke-normalfördelat, med stor variation, vilket påverkade val av statistiska metoder och tolkningen av resultaten.
- Statistiska analyser: Utmaningar uppstod med att förbättra resultaten från Shapiro-testet för normalitet och VIF-testet för multikollinearitet. Dessutom visade sig heteroskedasticitet vara en utmaning i regressionsmodeller, vilket krävde strategiska metodjusteringar för att få mer pålitliga resultat.

Lärdomar till vidare arbete: Projektet har tydliggjort vikten av noggrann datarensning, metodisk felsökning och flexibilitet i analysprocessen. Genom att arbeta systematiskt och identifiera problem tidigt kan framtida analyser effektiviseras och förbättras, tydlig planering kräv, flexibelt angreppssätt och arbeta metodiskt dag för dag, uppgift och rapportskrivning i ett kontinuerligt flöde. Absolut central att bryta ner projektet i mindre delmoment och lösa dessa systematiskt och praktiskt, steg för steg, kommer lösningen serverad på silverfat.

3. Vilket betyg anser du att du ska ha och varför?

Jag anser att jag bör få VG, eftersom jag har uppfyllt kursens centrala kriterier med hög säkerhet i genomförandet:

1. Datainsamling från SCB via API har skett metodiskt och korrekt enligt riktlinjerna.
2. Manuell datainsamling från Blocket har genomförts noggrant, med fokus på datakvalitet och struktur.
3. Regressionsmodellen, körts för att kunna prediktera försäljningspriset samt gjort en statistisk slutledning över modellen från en rad olika statistiska metoder och analysmetoder.
4. De givna teoretiska antaganden har analyserats i rapportens avsnitt *Undersökning av teoretiska antaganden*. Potentiella problem såsom normalfördelning, multikollinearitet och heteroskedasticitet har hanterats och diskuterats enligt teoriavsnitt.

Arbetet har präglats av självständighet, metodisk precision och tydlig dokumentation, vilket stärker motiveringen för ett högt betyg.

Appendix A

Källförteckning